資料探勘研究與實務-作業 5(Spark)

第三組

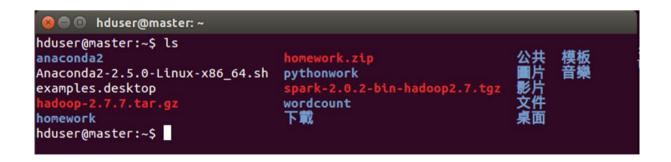
0753431 吳伯揚 0753425 李嘉晨

0753440 吳肇堉 0753423 劉奕辰

i. 截圖與步驟描述



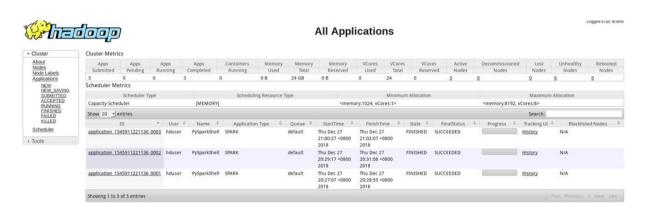
■ 安裝 Virtue Box 與相關網路、環境設定



■ 在虛擬機 Master 上 安裝 Hadoop, Spark, Anaconda 等相關套件

```
🖢 😑 hduser@master: ~
hduser@master:~$ hadoop fs -ls
 Found 3 items
drwxr-xr-x - hduser supergroup
drwxr-xr-x - hduser supergroup
drwxr-xr-x - hduser supergroup
                                                                   0 2018-12-27 21:02 .sparkStaging
0 2018-12-27 19:48 test
                                                                 0 2018-12-27 20:24 wordcount
hduser@master:~$ hadoop fs -ls test
 ound 4 items
-rw-r--r-- 3 hduser supergroup 1366 2018-12-27 19:15 test/README.txt
drwxr-xr-x - hduser supergroup 0 2018-12-27 19:17 test/etc
drwxr-xr-x - hduser supergroup 0 2018-12-27 20:15 test/homework
-rw-r--r-- 3 hduser supergroup 1366 2018-12-27 19:15 test/test1.txt
hduser@master:~$ hadoop fs -ls test/homework
 ound 3 items
                  3 hduser supergroup
 - FW- F-- F--
                                                         64170 2018-12-27 19:48 test/homework/final
.csv
 rw-r--r-- 3 hduser supergroup
rw-r--r-- 3 hduser supergroup
                                                              10 2018-12-27 20:15 test/homework/t.txt
1411 2018-12-27 19:48 test/homework/test.
hduser@master:~$
```

■ 建立 HDFS 目錄並放入資料集(CSV)



■ 其他三台虛擬機為 data node 並執行程式

ii. 作業目標對應之結果

■ Accuracy, Recall, Precision 結果

```
DecisionTreeModel classifier of depth 5 wi
 If (feature 6 <= 0.0)
   If (feature 7 <= 0.Ó)
    If (feature 23 <= 0.0)
If (feature 8 <= 0.0)
If (feature 21 <= 0.0)
      Predict: 1.0
      Else (feature 21 > 0.0)
       Predict: 0.0
     Else (feature 8 > 0.0)
      Predict: 0.0
   Else (feature 23 > 0.0)
     If (feature 0 <= 42.0)
      If (feature 0 <= 29.0)
      Predict: 0.0
      Else (feature 0 > 29.0)
       Predict: 1.0
     Else (feature 0 > 42.0)
      If (feature 2 <= 0.0)
       Predict: 0.0
      Else (feature 2 > 0.0)
       Predict: 0.0
  Else (feature 7 > 0.0)
    If (feature 0 <= 0.0)
     If (feature 4 <= 0.0)
      If (feature 1 <= 0.0)
       Predict: 0.0
      Else (feature 1 > 0.0)
       Predict: 1.0
    Else (feature 4 > 0.0)
      Predict: 0.0
   Else (feature 0 > 0.0)
     If (feature 13 <= 0.0)
      If (feature 24 <= 0.0)
       Predict: 0.0
      Else (feature 24 > 0.0)
       Predict: 0.0
     Else (feature 13 > 0.0)
      Predict: 1.0
 Else (feature 6 > 0.0)
   If (feature 0 <= 50.0)
    If (feature 23 <= 0.0)
     If (feature 14 <= 0.0)
If (feature 0 <= 29.0)
       Predict: 0.0
```

■ 產出決策樹模型(預測結果)

```
Else (feature 0 > 29.0)
   Predict: 0.0
 Else (feature 14 > 0.0)
   If (feature 0 <= 3.0)
   Predict: 1.0
  Else (feature 0 > 3.0)
    Predict: 0.0
Else (feature 23 > 0.0)
  If (feature 0 <= 14.0)
   If (feature 0 <= 6.0)
    Predict: 0.0
  Else (feature 0 > 6.0)
    Predict: 1.0
 Else (feature 0 > 14.0)
   If (feature 0 <= 33.0)
    Predict: 0.0
  Else (feature 0 > 33.0)
    Predict: 0.0
Else (feature 0 > 50.0)
 If (feature 4 <= 0.0)
  If (feature 2 <= 0.0)
  Predict: 1.0
 Else (feature 2 > 0.0)
   Predict: 0.0
Else (feature 4 > 0.0)
  If (feature 10 <= 0.0)
   If (feature 0 <= 58.0)
   Predict: 0.0
  Else (feature 0 > 58.0)
    Predict: 0.0
  Else (feature 10 > 0.0)
  Predict: 1.0
```

■ 產出決策樹模型(預測結果) (續上頁)

iii. 討論

此次分析與第一次作業相同,以預測腳色是否死亡為目的,其中 0 代表存活; 1 代表死亡,

模型主要是預測腳色是否會死亡,其中 Accuracy 有 64%,並且由死亡的 Precision(42%)以及 Recall(56%)可以看出模型似乎沒那麼好,並沒有太符合我們的需求。

當中原因可能是因為資料與死亡的關聯性沒有那麼大,導致預測腳色死亡時並不那麼準確。

而從存活的 Precision(78%)以及 Recall(67%)都遠大於死亡的 Precision(42%)以及 Recall(56%)可以得知由於大部分的腳色都存活,死亡的人數較少,所以模型傾向預測腳色存活使得存活的 Precision 以及 Recall 較高。